

Universidad Internacional Menéndez Pelayo

Máster Universitario en Investigación en Inteligencia Artificial

Sistemas multi-agente

Aprendizaje y modelado de valores en sistemas multiagente y su regulación mediante normas éticas

Estudiante: Javier Manuel Capilla Romerosa

Tutor: Sascha Ossowski

Curso: 2025–2026

Índice

I	Introducción	4
1.	Introducción	4
1.1.	Contexto y motivación	4
1.2.	Problema de la alineación de valores en IA	5
1.3.	Objetivos del trabajo	6
1.4.	Metodología y estructura del documento	6
II	Estado del arte y marco teórico	7
2.	Ética y valores en inteligencia artificial	7
2.1.	Inteligencia artificial responsable	7
2.2.	Principales teorías éticas aplicadas a agentes	8
2.3.	Diseño sensible a valores	9
3.	Sistemas multiagente basados en valores	9
3.1.	Representación de valores en agentes	10
3.2.	Toma de decisiones basada en valores	11
3.3.	Value-Aware Multi-Agent Systems	11
4.	Aprendizaje de valores en sistemas multiagente	12
4.1.	Problema de la especificación de valores	12
4.2.	Aprendizaje a partir de preferencias	13
4.3.	Modelado de sistemas de valores sociales	14
5.	Sistemas normativos alineados con valores	14
5.1.	Rol de las normas en sistemas multiagente	15
5.2.	Relación entre valores y normas	15
5.3.	Síntesis de sistemas normativos óptimos	16
III	Análisis de los trabajos seleccionados	17
6.	Análisis de los artículos seleccionados	17
6.1.	Responsible Autonomy	17
6.2.	Value-Aware Multiagent Systems	18
6.3.	Learning the Value Systems of Societies from Preferences	18
6.4.	Synthesis of Optimally Value-Aligned Normative Systems	19
6.5.	Specifying Agent Ethics	19

7. Comparación crítica de enfoques	20
7.1. Supuestos de partida	20
7.2. Diferencias metodológicas	20
7.3. Diferencias en objetivos	21
7.4. Limitaciones y problemas abiertos	22
 IV Propuesta e implementación	 22
8. Propuesta del sistema multiagente	22
8.1. Descripción del problema	23
8.2. Entorno Apollo y origen de los datos	24
8.3. Representación de valores y preferencias	24
8.4. Hipótesis de trabajo	25
9. Implementación del modelo	26
9.1. Procesamiento del dataset	26
9.2. Aprendizaje de pesos mediante preferencias	28
9.3. Agrupación de agentes y sistemas de valores sociales	30
9.4. Incorporación de normas	31
10. Diseño experimental	33
10.1. Configuración experimental	33
10.2. Comparación entre algoritmos de clustering	34
10.3. Evaluación del impacto normativo	35
10.4. Métricas utilizadas	35
10.4.1. Aprendizaje de valores	35
10.4.2. Clustering	35
10.4.3. Impacto normativo	36
 V Resultados y discusión	 36
11. Resultados	36
11.1. Sistemas de valores aprendidos	36
11.2. Resultados del clustering	38
11.3. Comparación entre K-Means, clustering jerárquico y GMM	39
11.4. Impacto global de las normas	40
11.5. Impacto de las normas por grupo social	42
12. Discusión	44
12.1. Relación con la literatura previa	44
12.2. Limitaciones del enfoque	45

12.3. Implicaciones para sistemas multiagente éticos	46
VI Conclusiones	47
13.Conclusiones y líneas futuras	47
13.1. Conclusiones principales	48
13.2. Líneas futuras de investigación	49
VII Bibliografía y material complementario	49
14.Bibliografía	50
15.Material complementario	50

Parte I

Introducción

1. Introducción

El desarrollo reciente de sistemas de inteligencia artificial cada vez más autónomos ha generado un creciente interés por garantizar que su comportamiento sea coherente con los valores humanos y los principios éticos de la sociedad. Este problema resulta especialmente relevante en sistemas multiagente, donde múltiples agentes autónomos interactúan entre sí, toman decisiones de forma distribuida y pueden perseguir objetivos diferentes o incluso conflictivos.

Tradicionalmente, muchos sistemas de inteligencia artificial han sido diseñados optimizando métricas puramente instrumentales como eficiencia, precisión o beneficio económico. Sin embargo, este enfoque resulta insuficiente en escenarios donde las decisiones tienen implicaciones éticas, sociales o normativas. En estos contextos, los agentes deben ser capaces no solo de maximizar utilidad, sino también de considerar valores como equidad, seguridad, privacidad o bienestar colectivo.

En los sistemas multiagente, este problema se vuelve aún más complejo debido a que distintos agentes pueden poseer sistemas de valores diferentes, lo que genera conflictos y dificultades de coordinación. Además, la definición explícita de dichos valores resulta especialmente complicada debido a su carácter subjetivo, contextual y dinámico.

En este contexto, han surgido distintas líneas de investigación orientadas a abordar este problema desde perspectivas complementarias: la inteligencia artificial responsable [1], los sistemas multiagente conscientes de valores [2], el aprendizaje de valores a partir de preferencias [3] y los sistemas normativos alineados con valores [4].

El presente trabajo se sitúa en la intersección de estas líneas de investigación y propone analizar tanto el estado del arte como una implementación práctica simplificada de un sistema multiagente basado en valores.

1.1. Contexto y motivación

La incorporación de inteligencia artificial en ámbitos como transporte, salud, finanzas, seguridad o administración pública ha incrementado la necesidad de desarrollar

sistemas capaces de tomar decisiones socialmente aceptables. En muchos de estos escenarios, las decisiones automáticas afectan directamente a personas y grupos sociales, por lo que resulta necesario considerar dimensiones éticas que van más allá del rendimiento técnico.

En particular, los sistemas multiagente representan un marco especialmente relevante para estudiar este problema debido a que modelan escenarios donde múltiples entidades autónomas interactúan simultáneamente. Ejemplos de ello incluyen vehículos autónomos, sistemas de recomendación distribuidos, mercados electrónicos o sistemas de coordinación logística.

La motivación principal de este trabajo surge de la necesidad de comprender cómo representar valores dentro de agentes artificiales, cómo aprender dichos valores a partir del comportamiento observado y cómo regular sus decisiones mediante normas cuando existen conflictos entre intereses individuales y objetivos colectivos.

1.2. Problema de la alineación de valores en IA

Uno de los principales desafíos actuales en inteligencia artificial consiste en garantizar que los sistemas autónomos actúen de acuerdo con valores humanos. Este problema es conocido como *value alignment problem* y constituye una de las cuestiones centrales de la ética computacional.

La principal dificultad radica en que los valores humanos no son universales ni estáticos. Diferentes individuos o grupos sociales pueden priorizar valores distintos e incluso contradictorios. Por ejemplo, en un sistema de movilidad autónoma algunos usuarios pueden priorizar rapidez, mientras que otros pueden priorizar comodidad o coste económico.

Además, traducir conceptos abstractos como justicia, autonomía o bienestar en mecanismos computacionales concretos resulta extremadamente complejo. La especificación manual de valores suele ser rígida y limitada, por lo que han surgido enfoques alternativos basados en aprendizaje a partir de preferencias observadas [3].

En sistemas multiagente, este problema se amplifica debido a la coexistencia de múltiples agentes con sistemas de valores potencialmente heterogéneos, lo que hace necesaria la incorporación de mecanismos adicionales de coordinación y regulación mediante normas [4].

1.3. Objetivos del trabajo

El objetivo general de este trabajo es estudiar cómo pueden modelarse, aprenderse y regularse los valores en sistemas multiagente.

De forma más específica, los objetivos particulares son:

- Analizar el estado del arte sobre ética en inteligencia artificial y sistemas multiagente basados en valores.
- Estudiar los principales trabajos recientes sobre aprendizaje de valores y regulación normativa.
- Comparar críticamente los enfoques existentes, identificando sus principales diferencias, supuestos y limitaciones.
- Implementar una versión simplificada de un sistema de aprendizaje de valores a partir de preferencias inspirado en Holgado-Sánchez et al. [3].
- Analizar la formación de grupos sociales mediante técnicas de clustering sobre sistemas de valores aprendidos.
- Evaluar el impacto de normas sobre la toma de decisiones de agentes con diferentes sistemas de valores.

1.4. Metodología y estructura del documento

El trabajo combina una metodología teórica y experimental.

En primer lugar, se realiza una revisión bibliográfica de los principales trabajos relacionados con inteligencia artificial responsable, sistemas multiagente basados en valores, aprendizaje de preferencias y sistemas normativos.

Posteriormente, se lleva a cabo un análisis comparativo de los artículos seleccionados con el objetivo de identificar similitudes, diferencias metodológicas y problemas abiertos.

En la parte práctica, se utiliza el entorno Apollo empleado por Holgado-Sánchez et al. [3] para generar datos de preferencias entre rutas alternativas. A partir de estos datos, se implementa un modelo simplificado de aprendizaje de valores mediante regresión logística, se aplican distintos algoritmos de clustering para identificar grupos sociales y finalmente se incorpora una capa normativa para estudiar su impacto en el comportamiento de los agentes.

El documento se organiza en siete partes principales: introducción, estado del arte y

marco teórico, análisis de trabajos seleccionados, propuesta e implementación, resultados y discusión, conclusiones, y finalmente bibliografía y material complementario.

Parte II

Estado del arte y marco teórico

2. Ética y valores en inteligencia artificial

El rápido avance de los sistemas de inteligencia artificial ha generado importantes beneficios en múltiples sectores, pero también ha planteado nuevos desafíos éticos y sociales. A medida que los sistemas autónomos adquieren una mayor capacidad de decisión, resulta cada vez más necesario garantizar que su comportamiento sea compatible con valores humanos y principios normativos aceptables.

Durante muchos años, el desarrollo de sistemas de inteligencia artificial estuvo centrado principalmente en métricas técnicas como precisión, eficiencia o rendimiento económico. Sin embargo, este enfoque ha demostrado ser insuficiente en escenarios donde las decisiones automatizadas afectan directamente a personas o grupos sociales. Problemas relacionados con discriminación algorítmica, pérdida de privacidad, falta de transparencia o decisiones moralmente cuestionables han impulsado el desarrollo de nuevas líneas de investigación centradas en la ética de la inteligencia artificial.

En este contexto, han surgido distintos enfoques orientados a incorporar valores humanos en el diseño y funcionamiento de sistemas inteligentes. Entre ellos destacan la inteligencia artificial responsable, el diseño sensible a valores y los trabajos orientados a especificar formalmente comportamientos éticos en agentes autónomos.

2.1. Inteligencia artificial responsable

Uno de los enfoques más influyentes en este ámbito es el de *Responsible Artificial Intelligence*. Este paradigma propone que los sistemas de IA deben diseñarse teniendo en cuenta no solo objetivos funcionales, sino también su impacto social, ético y legal.

Dignum [1] introduce el concepto de *Responsible Autonomy*, argumentando que el problema principal no consiste únicamente en crear sistemas autónomos más capa-

ces, sino en garantizar que dicha autonomía esté limitada por principios éticos y mecanismos de control adecuados.

La autora plantea tres niveles fundamentales:

- **Ética en el diseño:** garantizar que el sistema ha sido desarrollado de forma responsable.
- **Ética por diseño:** incorporar mecanismos éticos dentro del propio sistema.
- **Ética en uso:** analizar cómo las personas utilizan los sistemas desarrollados.

Este enfoque resulta especialmente relevante para sistemas multiagente, ya que la autonomía distribuida incrementa la complejidad de supervisar el comportamiento global del sistema.

Además, Dignum señala que los sistemas autónomos deben ser capaces de justificar sus decisiones y actuar dentro de límites éticos previamente definidos, lo que conecta directamente con los problemas de alineación de valores estudiados en este trabajo.

2.2. Principales teorías éticas aplicadas a agentes

La ética computacional ha tratado de trasladar teorías éticas clásicas al ámbito de los agentes artificiales. Aunque estas teorías fueron originalmente desarrolladas en filosofía moral, han servido como base conceptual para diseñar sistemas autónomos capaces de tomar decisiones éticas.

Entre las principales aproximaciones destacan:

- **Utilitarismo:** evalúa las acciones según sus consecuencias y busca maximizar el bienestar agregado.
- **Deontología:** se centra en el cumplimiento de reglas, deberes y obligaciones.
- **Ética de la virtud:** prioriza el desarrollo de comportamientos moralmente deseables.

En sistemas multiagente, estas aproximaciones presentan limitaciones importantes. El utilitarismo puede ignorar derechos individuales, la deontología puede resultar demasiado rígida y la ética de la virtud es difícil de formalizar computacionalmente.

Dennis y Fisher [5] analizan precisamente las dificultades de especificar comportamientos éticos en agentes autónomos, señalando problemas como ambigüedad moral, conflictos entre principios y dificultades de verificación formal.

Estas limitaciones han motivado el desarrollo de enfoques alternativos basados en valores, donde los agentes no siguen únicamente reglas rígidas ni optimizan exclusivamente consecuencias globales, sino que razonan sobre múltiples dimensiones valorativas.

2.3. Diseño sensible a valores

El enfoque de *Value Sensitive Design* propone incorporar valores humanos desde las primeras fases del diseño tecnológico.

A diferencia de enfoques que introducen restricciones éticas únicamente durante la fase de despliegue, este paradigma defiende que los valores deben estar presentes desde el diseño inicial de los sistemas.

Este enfoque resulta especialmente útil porque reconoce que los sistemas tecnológicos nunca son neutrales: las decisiones de diseño incorporan implícitamente determinadas prioridades y pueden favorecer unos valores frente a otros.

En el contexto de inteligencia artificial, esto implica identificar qué valores son relevantes en cada dominio y traducirlos posteriormente en mecanismos computacionales concretos.

Sin embargo, uno de los principales problemas de este enfoque es que asume que dichos valores pueden ser definidos explícitamente de antemano, algo que en muchos escenarios reales resulta extremadamente difícil debido a la diversidad de preferencias y valores presentes en la sociedad.

Precisamente esta limitación ha impulsado enfoques más recientes centrados en el aprendizaje automático de valores a partir de preferencias observadas, que serán analizados en secciones posteriores.

3. Sistemas multiagente basados en valores

Los sistemas multiagente (*Multi-Agent Systems*, MAS) están compuestos por múltiples agentes autónomos que interactúan entre sí dentro de un entorno compartido. Estos agentes pueden cooperar, competir, negociar o coordinarse para alcanzar objetivos individuales o colectivos.

Tradicionalmente, gran parte de la investigación en sistemas multiagente se ha centrado en problemas de coordinación, optimización, negociación y toma de decisiones racional basada en utilidad. En estos modelos clásicos, los agentes suelen perseguir

objetivos definidos explícitamente y toman decisiones maximizando funciones de utilidad predefinidas.

Sin embargo, este enfoque presenta limitaciones importantes cuando los agentes operan en contextos sociales complejos donde las decisiones tienen implicaciones éticas. En estos escenarios, maximizar únicamente utilidad puede conducir a comportamientos socialmente indeseables o incompatibles con valores humanos.

Como respuesta a estas limitaciones, han surgido enfoques que incorporan explícitamente valores dentro de la arquitectura de los agentes. Estos modelos permiten representar conflictos entre distintos valores y razonar sobre ellos durante el proceso de toma de decisiones [2].

3.1. Representación de valores en agentes

Uno de los principales desafíos de los sistemas multiagente basados en valores consiste en representar computacionalmente conceptos abstractos como justicia, seguridad, privacidad o bienestar.

En términos generales, un valor puede entenderse como un principio abstracto que influye en las preferencias y decisiones de un agente. A diferencia de los objetivos, que suelen ser concretos y específicos, los valores actúan como criterios más generales que orientan el comportamiento.

Existen múltiples formas de representar valores en sistemas artificiales:

- Mediante reglas explícitas.
- Mediante funciones de utilidad multiatributo.
- Mediante jerarquías de prioridades.
- Mediante restricciones normativas.

En el contexto de este trabajo, los valores se representan mediante pesos numéricos asociados a distintas dimensiones de decisión. Esta representación permite modelar diferencias individuales entre agentes y facilita posteriormente el aprendizaje automático de dichos valores a partir de preferencias observadas.

Por ejemplo, en un problema de movilidad un agente puede priorizar rapidez mientras otro puede priorizar coste o comodidad. Aunque ambos enfrentan el mismo entorno, sus decisiones pueden diferir debido a sus sistemas de valores distintos.

3.2. Toma de decisiones basada en valores

Una vez representados los valores, los agentes deben utilizarlos para seleccionar entre diferentes alternativas disponibles.

En modelos clásicos de decisión racional, un agente selecciona la alternativa que maximiza una función de utilidad. En sistemas basados en valores, esta función puede ampliarse incorporando múltiples dimensiones valorativas.

Formalmente, una decisión puede modelarse como una combinación de:

- características del entorno,
- consecuencias de cada acción,
- importancia relativa de cada valor.

En este contexto, diferentes agentes pueden llegar a decisiones distintas incluso cuando observan exactamente las mismas alternativas, simplemente porque asignan pesos diferentes a cada valor.

Este problema es especialmente relevante en sociedades heterogéneas, donde distintos individuos pueden mantener prioridades incompatibles. La coexistencia de múltiples sistemas de valores genera conflictos que requieren mecanismos adicionales de coordinación.

En la parte práctica de este trabajo, este proceso se modelará mediante funciones de utilidad lineales que combinan distintos valores aprendidos a partir de preferencias observadas.

3.3. Value-Aware Multi-Agent Systems

Uno de los trabajos más recientes y relevantes en este ámbito es el propuesto por Osman [2], quien introduce el concepto de *Value-Aware Multi-Agent Systems*.

Este enfoque propone extender los sistemas multiagente tradicionales incorporando explícitamente valores dentro de los procesos de razonamiento de los agentes.

Según Osman, un sistema multiagente consciente de valores debe ser capaz de:

- identificar valores relevantes,
- representar dichos valores,
- razonar sobre conflictos entre valores,
- adaptar el comportamiento de los agentes en consecuencia.

El artículo destaca que muchos sistemas multiagente actuales ignoran completamente dimensiones éticas y sociales, lo que limita su aplicabilidad en escenarios reales.

Además, Osman subraya la importancia de considerar que distintos agentes pueden mantener sistemas de valores diferentes, lo que conecta directamente con el problema de diversidad de valores estudiado posteriormente por Holgado-Sánchez et al. [3].

En este sentido, los sistemas multiagente conscientes de valores constituyen el puente conceptual entre la ética en inteligencia artificial y los modelos computacionales de aprendizaje y regulación que se analizan en las siguientes secciones.

4. Aprendizaje de valores en sistemas multiagente

Uno de los principales problemas de los sistemas multiagente basados en valores consiste en determinar cuáles son exactamente los valores que deben guiar el comportamiento de los agentes. Aunque la literatura ha propuesto múltiples modelos para representar valores de forma explícita, en muchos escenarios reales resulta extremadamente difícil definir manualmente dichos sistemas de valores.

Esta dificultad ha impulsado el desarrollo de enfoques de aprendizaje automático orientados a inferir valores a partir del comportamiento observado de individuos o grupos sociales. En lugar de especificar manualmente qué valores deben seguir los agentes, estos modelos intentan aprenderlos a partir de preferencias, decisiones históricas o ejemplos de comportamiento humano.

Este enfoque resulta especialmente atractivo en contextos donde existe diversidad de valores entre distintos individuos, ya que permite modelar sociedades heterogéneas sin asumir que todos los agentes comparten exactamente las mismas prioridades.

4.1. Problema de la especificación de valores

La especificación explícita de valores constituye uno de los principales retos de la ética computacional. Traducir conceptos abstractos como justicia, autonomía, seguridad o bienestar en estructuras computacionales concretas resulta extremadamente complejo.

En muchos casos, los diseñadores deben decidir manualmente qué valores incorporar al sistema y cómo priorizarlos. Este enfoque presenta varias limitaciones importantes:

- Puede introducir sesgos de los diseñadores.

- Resulta difícil representar contextos dinámicos.
- No captura adecuadamente la diversidad social.
- Puede generar sistemas demasiado rígidos.

Dennis y Fisher [5] discuten precisamente las dificultades de especificar formalmente comportamientos éticos en agentes autónomos. Los autores destacan que incluso cuando existe consenso sobre principios generales, su implementación computacional puede generar conflictos e inconsistencias.

En sistemas multiagente, este problema se vuelve aún más complejo debido a que diferentes agentes pueden mantener preferencias incompatibles. Esto hace que la especificación manual sea aún menos viable en entornos sociales complejos.

4.2. Aprendizaje a partir de preferencias

Una alternativa a la especificación manual consiste en inferir valores observando decisiones realizadas por individuos o agentes.

La idea central de este enfoque es que las preferencias reveladas contienen información sobre los valores subyacentes que motivan dichas decisiones. Si un agente selecciona repetidamente determinadas alternativas frente a otras, es posible inferir qué dimensiones valora más.

Este paradigma está relacionado con áreas como:

- aprendizaje por preferencias,
- *inverse reinforcement learning*,
- aprendizaje de utilidad.

En este contexto, Holgado-Sánchez et al. [3] proponen uno de los enfoques más recientes y relevantes para este trabajo.

Los autores presentan un modelo capaz de inferir sistemas de valores de sociedades completas a partir de preferencias observadas entre distintas alternativas. Para ello utilizan el entorno Apollo, donde los agentes deben elegir entre diferentes rutas caracterizadas por múltiples dimensiones de valor.

A partir de estas elecciones, el modelo estima qué importancia asigna cada agente a distintos valores y posteriormente identifica patrones colectivos dentro de la sociedad.

Este enfoque resulta especialmente relevante para este trabajo porque constituye la principal inspiración de la parte práctica desarrollada posteriormente. No obstante, en lugar de replicar exactamente su modelo original, se implementará una versión simplificada basada en regresión logística sobre diferencias de valores.

4.3. Modelado de sistemas de valores sociales

Además de aprender valores individuales, uno de los principales avances del trabajo de Holgado-Sánchez et al. [3] consiste en modelar sociedades como conjuntos de grupos con sistemas de valores diferenciados.

Los autores argumentan que asumir una única función de valores global para toda la sociedad resulta poco realista. En la práctica, diferentes grupos sociales pueden priorizar valores distintos e incluso conflictivos.

Por ejemplo:

- algunos individuos pueden priorizar eficiencia,
- otros pueden priorizar coste,
- otros pueden priorizar comodidad.

Este problema introduce una dimensión colectiva que va más allá del aprendizaje individual y conecta directamente con cuestiones de gobernanza, coordinación y conflicto social.

En la parte experimental de este trabajo, esta idea será abordada mediante técnicas de clustering aplicadas a los sistemas de valores aprendidos individualmente. Esto permitirá identificar grupos de agentes con prioridades similares y analizar cómo las normas afectan de forma diferente a cada grupo social.

5. Sistemas normativos alineados con valores

La existencia de múltiples agentes con sistemas de valores diferentes plantea un problema fundamental de coordinación social. Incluso si cada agente toma decisiones coherentes con sus propios valores, el comportamiento agregado del sistema puede generar conflictos, externalidades negativas o resultados socialmente indeseables.

En estos contextos, los sistemas normativos constituyen un mecanismo clásico de regulación dentro de los sistemas multiagente. Las normas permiten restringir, in-

centivar o penalizar determinadas acciones con el objetivo de garantizar comportamientos compatibles con objetivos colectivos.

Tradicionalmente, la investigación en sistemas normativos multiagente se ha centrado en reglas, obligaciones, permisos y sanciones. Sin embargo, enfoques recientes han comenzado a estudiar cómo diseñar normas que estén explícitamente alineadas con valores sociales [4].

Esta línea de investigación resulta especialmente relevante en escenarios donde existe diversidad de valores, ya que las normas pueden actuar como mecanismos de coordinación cuando los agentes mantienen prioridades incompatibles.

5.1. Rol de las normas en sistemas multiagente

En sistemas multiagente, las normas permiten regular interacciones entre agentes autónomos sin eliminar completamente su autonomía.

En lugar de controlar directamente todas las decisiones individuales, las normas establecen límites dentro de los cuales los agentes pueden actuar libremente.

Entre sus principales funciones destacan:

- reducir conflictos entre agentes,
- mejorar coordinación colectiva,
- evitar comportamientos perjudiciales,
- garantizar cumplimiento de objetivos globales.

Por ejemplo, en sistemas de tráfico autónomo las normas pueden limitar ciertas decisiones individuales para garantizar seguridad colectiva. De forma similar, en mercados electrónicos pueden prevenir comportamientos oportunistas.

En contextos éticos, las normas resultan especialmente útiles cuando los valores individuales no están alineados con objetivos sociales más amplios.

5.2. Relación entre valores y normas

Aunque valores y normas están relacionados, representan niveles distintos dentro del proceso de toma de decisiones.

Los valores son principios abstractos que guían preferencias individuales, mientras que las normas constituyen mecanismos concretos de regulación externa.

En términos generales:

- Los valores influyen en cómo los agentes desean actuar.
- Las normas limitan cómo los agentes pueden actuar.

Cuando todos los agentes comparten valores similares, la necesidad de regulación normativa puede ser menor. Sin embargo, en sociedades heterogéneas donde existen conflictos entre prioridades individuales, las normas pueden desempeñar un papel fundamental.

Este problema resulta especialmente relevante en el contexto de este trabajo, donde se identifican grupos de agentes con sistemas de valores distintos. En este escenario, una misma norma puede afectar de forma desigual a distintos grupos sociales.

Esta idea será analizada experimentalmente en la parte práctica mediante la introducción de penalizaciones normativas sobre determinadas decisiones.

5.3. Síntesis de sistemas normativos óptimos

Uno de los trabajos más relevantes en esta línea es el propuesto por Montes y Sierra [4].

Los autores estudian cómo generar automáticamente sistemas normativos que maximicen la alineación con determinados valores sociales. En lugar de diseñar normas manualmente, su enfoque busca sintetizar automáticamente conjuntos normativos óptimos.

El modelo analiza:

- qué normas deben aplicarse,
- qué comportamientos restringen,
- qué valores promueven,
- qué efectos generan sobre el sistema global.

Uno de los principales aportes de este trabajo es mostrar que distintas configuraciones normativas pueden producir resultados muy diferentes dependiendo de los valores que se intenten proteger.

Este enfoque resulta especialmente relevante para el presente trabajo porque proporciona el marco conceptual para estudiar cómo las normas pueden modificar decisiones en sistemas multiagente con diversidad de valores.

No obstante, en lugar de implementar un sistema completo de síntesis normativa automática, en este trabajo se utilizará una versión simplificada basada en penalizaciones sobre determinadas dimensiones de valor, lo que permitirá analizar experimentalmente cómo las normas afectan a diferentes grupos de agentes.

Parte III

Análisis de los trabajos seleccionados

6. Análisis de los artículos seleccionados

Con el objetivo de comprender el estado actual de la investigación sobre sistemas multiagente éticos y basados en valores, este trabajo analiza cinco artículos recientes que abordan el problema desde perspectivas complementarias.

Los trabajos seleccionados cubren diferentes niveles del problema: fundamentos éticos generales, representación de valores, aprendizaje automático de sistemas de valores y regulación normativa. En conjunto, permiten construir una visión relativamente completa del problema de alineación de valores en sistemas multiagente.

6.1. Responsible Autonomy

El trabajo de Dignum [1] constituye una de las referencias más relevantes dentro del ámbito de la inteligencia artificial responsable.

La autora argumenta que el aumento de la autonomía de los sistemas inteligentes requiere nuevos mecanismos de supervisión ética. Su principal contribución consiste en introducir el concepto de *Responsible Autonomy*, que plantea que la autonomía de los sistemas debe estar limitada por principios éticos y mecanismos de control adecuados.

El artículo propone distinguir entre tres dimensiones:

- ética en el diseño,
- ética por diseño,

- ética en uso.

Su principal aportación es proporcionar un marco conceptual amplio para entender cómo integrar principios éticos en sistemas autónomos. Sin embargo, el artículo se mantiene en un nivel relativamente abstracto y no propone mecanismos concretos de implementación en sistemas multiagente.

6.2. Value-Aware Multiagent Systems

El trabajo de Osman [2] se centra específicamente en la incorporación de valores dentro de sistemas multiagente.

La autora introduce el concepto de *Value-Aware Multi-Agent Systems*, argumentando que los sistemas multiagente tradicionales han prestado poca atención a dimensiones éticas y sociales.

El artículo propone que los agentes deben ser capaces de:

- identificar valores relevantes,
- representar dichos valores,
- razonar sobre conflictos entre valores,
- adaptar su comportamiento.

Su principal contribución consiste en trasladar explícitamente la discusión ética al ámbito de los sistemas multiagente. No obstante, el trabajo se encuentra todavía en una fase conceptual y no desarrolla mecanismos concretos de aprendizaje o implementación.

6.3. Learning the Value Systems of Societies from Preferences

El trabajo de Holgado-Sánchez et al. [3] representa una de las contribuciones más relevantes para este proyecto.

Los autores proponen un modelo capaz de inferir sistemas de valores de individuos y sociedades completas a partir de preferencias observadas entre distintas alternativas.

Para ello utilizan el entorno Apollo, donde los agentes deben elegir entre rutas alternativas caracterizadas por múltiples dimensiones de valor.

El modelo permite:

- aprender valores individuales,
- identificar grupos sociales,
- modelar diversidad de valores.

Este trabajo constituye la principal inspiración de la parte experimental desarrollada en este proyecto, aunque se implementa una versión simplificada de su enfoque original.

6.4. Synthesis of Optimally Value-Aligned Normative Systems

El trabajo de Montes y Sierra [4] aborda el problema desde la perspectiva de regulación normativa.

Los autores proponen mecanismos automáticos para sintetizar sistemas normativos alineados con determinados valores sociales.

En lugar de diseñar normas manualmente, su modelo busca identificar automáticamente qué conjunto de normas maximiza la alineación con ciertos valores deseados.

El trabajo resulta especialmente relevante porque conecta directamente los conceptos de valores y regulación normativa dentro de sistemas multiagente.

6.5. Specifying Agent Ethics

El trabajo de Dennis y Fisher [5] estudia uno de los problemas más complejos dentro de la ética computacional: cómo especificar formalmente comportamientos éticos en agentes autónomos.

Los autores analizan las dificultades de traducir principios éticos abstractos en reglas computacionales concretas.

Entre los principales problemas identificados destacan:

- ambigüedad moral,
- conflictos entre principios,
- dificultades de verificación formal.

Este trabajo resulta especialmente útil porque muestra las limitaciones de enfoques puramente basados en especificación manual, justificando la necesidad de métodos de aprendizaje automático como los utilizados posteriormente por Holgado et al.

7. Comparación crítica de enfoques

Aunque los trabajos analizados abordan el problema de la ética en sistemas autónomos desde perspectivas diferentes, todos comparten una preocupación común: garantizar que el comportamiento de los agentes artificiales sea compatible con valores humanos y objetivos socialmente aceptables.

Sin embargo, difieren significativamente en sus supuestos de partida, metodologías y nivel de formalización. Esta sección compara críticamente dichos enfoques con el objetivo de identificar sus principales fortalezas, limitaciones y puntos de conexión.

7.1. Supuestos de partida

Una de las principales diferencias entre los trabajos analizados se encuentra en los supuestos iniciales sobre cómo deben incorporarse los valores en sistemas artificiales.

Dignum [1] parte de una perspectiva institucional y normativa amplia, asumiendo que los sistemas deben diseñarse desde principios éticos generales. Su enfoque presupone que es posible definir dichos principios de forma relativamente clara desde fases tempranas del diseño.

De forma similar, Dennis y Fisher [5] asumen que los principios éticos pueden formalizarse explícitamente dentro de sistemas computacionales, aunque reconocen importantes dificultades prácticas.

Por el contrario, Holgado-Sánchez et al. [3] parten de una hipótesis diferente: los valores no deben especificarse manualmente, sino inferirse a partir de preferencias observadas. Este enfoque asume que las decisiones reveladas contienen información suficiente para reconstruir sistemas de valores subyacentes.

Osman [2] adopta una posición intermedia al centrarse en cómo representar valores dentro de sistemas multiagente sin definir un mecanismo concreto para obtenerlos.

Finalmente, Montes y Sierra [4] asumen que los valores ya han sido definidos previamente y centran su trabajo en diseñar normas alineadas con dichos valores.

7.2. Diferencias metodológicas

Las diferencias metodológicas entre los artículos son especialmente significativas.

Dignum y Osman presentan marcos principalmente conceptuales. Sus trabajos aportan definiciones, principios y líneas de investigación, pero no desarrollan implementaciones experimentales complejas.

Dennis y Fisher también mantienen un enfoque predominantemente teórico centrado en problemas de especificación formal.

En contraste, Holgado-Sánchez et al. [3] presentan un enfoque claramente computacional y experimental basado en aprendizaje automático a partir de preferencias.

Por su parte, Montes y Sierra [4] proponen modelos formales de optimización para sintetizar sistemas normativos.

Por tanto, puede observarse una clara división entre:

- enfoques conceptuales,
- enfoques de aprendizaje,
- enfoques de optimización normativa.

7.3. Diferencias en objetivos

Los objetivos de los trabajos también difieren considerablemente.

Dignum busca establecer principios generales para una IA responsable.

Osman pretende adaptar estos principios al contexto específico de los sistemas multiagente.

Dennis y Fisher estudian cómo formalizar éticamente agentes autónomos.

Holgado-Sánchez et al. intentan resolver el problema del aprendizaje de valores en sociedades heterogéneas.

Montes y Sierra se centran en regular sistemas ya existentes mediante normas óptimas.

En cierto sentido, estos trabajos pueden entenderse como piezas complementarias de un mismo problema global:

1. definir principios éticos,
2. representar valores,
3. aprender valores,
4. regular comportamientos.

7.4. Limitaciones y problemas abiertos

A pesar de sus contribuciones, todos los enfoques presentan limitaciones importantes.

Los enfoques conceptuales suelen carecer de validación experimental.

Los enfoques de especificación manual presentan dificultades para representar diversidad social y cambios contextuales.

Los modelos de aprendizaje dependen fuertemente de la calidad de los datos observados y pueden presentar problemas de interpretabilidad.

Los modelos normativos pueden generar tensiones entre regulación colectiva y autonomía individual.

Además, ninguno de los trabajos analizados resuelve completamente el problema de integrar simultáneamente:

- aprendizaje de valores,
- diversidad social,
- toma de decisiones,
- regulación normativa.

Precisamente este vacío constituye la principal motivación de la parte práctica desarrollada en este trabajo, donde se propone una aproximación simplificada que combina aprendizaje de valores, agrupación social y regulación normativa dentro de un mismo sistema experimental.

Parte IV

Propuesta e implementación

8. Propuesta del sistema multiagente

Tras analizar los principales enfoques existentes sobre ética computacional, aprendizaje de valores y sistemas normativos, esta sección presenta la propuesta práctica desarrollada en este trabajo.

El objetivo principal consiste en construir un entorno experimental simplificado que permita integrar de forma conjunta varios de los elementos estudiados en la literatura:

- aprendizaje de valores individuales,
- diversidad de valores sociales,
- agrupación de agentes,
- regulación normativa.

Como se ha observado en el análisis crítico de la literatura, los trabajos existentes suelen abordar únicamente partes aisladas de este problema. Algunos se centran en la representación ética, otros en el aprendizaje de valores y otros en el diseño normativo.

Sin embargo, pocos trabajos integran simultáneamente estos componentes dentro de un mismo pipeline experimental.

La propuesta desarrollada en este trabajo busca precisamente explorar dicha integración mediante una arquitectura simplificada pero reproducible que permita analizar cómo emergen sistemas de valores colectivos y cómo las normas afectan de manera desigual a distintos grupos sociales.

8.1. Descripción del problema

El problema experimental puede formularse del siguiente modo:

Dado un conjunto de agentes que toman decisiones entre alternativas caracterizadas por múltiples dimensiones de valor, se pretende:

1. inferir los sistemas de valores individuales de cada agente,
2. identificar grupos sociales con prioridades similares,
3. introducir restricciones normativas,
4. analizar cómo dichas normas modifican el comportamiento colectivo.

Cada agente observa pares de alternativas y expresa preferencias entre ellas. Estas preferencias contienen información implícita sobre la importancia relativa que cada agente asigna a distintos valores.

Posteriormente, los agentes son agrupados en función de sus sistemas de valores aprendidos para modelar sociedades heterogéneas.

Finalmente, se introduce una capa normativa externa que modifica ciertas decisiones individuales con el objetivo de analizar conflictos entre autonomía individual y regulación colectiva.

8.2. Entorno Apollo y origen de los datos

La base experimental utilizada en este trabajo proviene del entorno Apollo desarrollado por Holgado-Sánchez et al. [3].

Apollo es un entorno de simulación donde agentes deben elegir entre rutas alternativas caracterizadas por múltiples dimensiones de valor.

Cada decisión involucra comparaciones entre trayectorias que presentan distintos niveles de alineación con varios valores.

En el repositorio original, los datos se almacenan mediante estructuras serializadas en formato `.pkl`, que contienen objetos complejos definidos por clases internas del propio sistema.

Aunque esta implementación resulta adecuada para el experimento original, introduce importantes dificultades de reproducibilidad:

- dependencias externas,
- objetos serializados complejos,
- necesidad de ejecutar el entorno original.

Para evitar estas limitaciones, se extrajo únicamente la información necesaria para este trabajo y se construyó un dataset tabular independiente.

De este modo, el proyecto puede ejecutarse de forma completamente autónoma sin depender del entorno original.

8.3. Representación de valores y preferencias

El dataset final utilizado en este trabajo se almacena en el archivo:

`apollo_preferences_dataset.csv`

Cada fila representa una comparación entre dos alternativas:

- alternativa A
- alternativa B

Para cada alternativa se dispone de tres dimensiones de valor:

- v_1
- v_2
- v_3

En el entorno original Apollo, estas dimensiones representan distintos criterios utilizados por los agentes para evaluar trayectorias alternativas.

En esta implementación simplificada, dichas dimensiones se interpretan como tres valores abstractos que capturan prioridades potencialmente conflictivas entre agentes.

Además, el dataset incluye:

- identificador del agente,
- identificador de comparación,
- alternativa elegida,
- preferencias específicas por valor.

Formalmente, cada decisión puede representarse como:

$$(A(v_1, v_2, v_3), B(v_1, v_2, v_3))$$

donde el agente selecciona una de las dos alternativas disponibles.

Esta representación permite modelar explícitamente la relación entre preferencias observadas y valores subyacentes.

8.4. Hipótesis de trabajo

La propuesta experimental se construye sobre cuatro hipótesis principales.

H1: Es posible inferir sistemas de valores individuales a partir de preferencias observadas.

H2: Los agentes pueden agruparse en comunidades relativamente homogéneas según sus sistemas de valores.

H3: Diferentes algoritmos de clustering producen niveles distintos de calidad e interpretabilidad.

H4: Las normas afectan de manera desigual a diferentes grupos sociales dependiendo de sus prioridades valorativas.

Estas hipótesis estructuran los experimentos desarrollados en las siguientes secciones y permiten evaluar empíricamente múltiples aspectos del problema de alineación de valores en sistemas multiagente.

9. Implementación del modelo

Una vez definida la propuesta experimental, se desarrolló una implementación modular compuesta por varias fases secuenciales que permiten reproducir todo el pipeline de análisis.

La implementación fue desarrollada en Python utilizando bibliotecas estándar de análisis de datos y aprendizaje automático como `pandas`, `numpy`, `scikit-learn` y `matplotlib`.

Con el objetivo de mejorar la reproducibilidad, cada fase del pipeline fue implementada mediante scripts independientes y los resultados intermedios se almacenan automáticamente en archivos CSV.

La arquitectura final del sistema sigue la siguiente secuencia:

$$dataset \rightarrow aprendizaje \rightarrow clustering \rightarrow normas \rightarrow visualización$$

9.1. Procesamiento del dataset

El primer paso consistió en transformar el dataset original procedente de Apollo en un formato adecuado para el análisis experimental.

Los datos originales estaban almacenados en estructuras serializadas en formato `.pkl`, concretamente en el archivo `dataset_train.pkl`. Dicho archivo contenía objetos complejos definidos dentro del repositorio original de Holgado-Sánchez et al. [3], lo que dificultaba su reutilización directa fuera de dicho entorno.

Cada observación del dataset seguía la siguiente estructura:

$$((traj_A, traj_B), pref, pref_values, comparison_id)$$

donde:

- `traj_A` representa la primera trayectoria candidata,
- `traj_B` representa la segunda trayectoria candidata,
- `pref` indica qué alternativa fue preferida por el agente,
- `pref_values` contiene información adicional sobre preferencias a nivel de valor,
- `comparison_id` identifica cada comparación.

Cada trayectoria estaba representada mediante objetos de tipo `TrajectoryWithValueSystemRews`, que incluían vectores internos denominados `v_rews`. Estos vectores almacenaban el rendimiento de cada trayectoria respecto a las distintas dimensiones valorativas del entorno.

Dado que en el entorno Apollo las trayectorias utilizadas en este experimento presentan una longitud muy reducida, se agregaron estos vectores para obtener una representación simplificada de cada alternativa:

$$(v_1, v_2, v_3)$$

Posteriormente, para cada comparación entre alternativas se extrajo:

- identificador del agente,
- identificador de comparación,
- alternativa elegida,
- valores de la alternativa A,
- valores de la alternativa B.

Adicionalmente, se calcularon diferencias entre ambas alternativas:

$$\Delta v_i = v_i^A - v_i^B$$

El cálculo de estas diferencias responde a la propia naturaleza del problema de decisión planteado.

Cada observación no representa una evaluación aislada de una alternativa, sino una elección binaria entre dos trayectorias competidoras.

Por tanto, lo relevante no es únicamente el valor absoluto de cada alternativa, sino su rendimiento relativo frente a la otra opción disponible.

Representar cada observación mediante diferencias permite capturar explícitamente este trade-off:

- si $\Delta v_i > 0$, la alternativa A obtiene mejor rendimiento en el valor i
- si $\Delta v_i < 0$, la alternativa B obtiene mejor rendimiento en el valor i

Esta representación resulta especialmente adecuada para el modelo de regresión logística posterior, ya que permite estimar cómo las diferencias entre alternativas influyen directamente en la probabilidad de elección del agente.

Finalmente, toda la información fue almacenada en un dataset tabular independiente:

`apollo_preferences_dataset.csv`

Esta transformación permitió eliminar completamente la dependencia del repositorio original y mejorar significativamente la reproducibilidad del experimento.

9.2. Aprendizaje de pesos mediante preferencias

El objetivo de esta fase consiste en inferir la importancia relativa que cada agente asigna a cada dimensión de valor.

Para ello, se utilizó un modelo de regresión logística binaria independiente para cada agente.

La elección de regresión logística responde a varias razones metodológicas.

En primer lugar, el problema planteado consiste en una decisión binaria entre dos alternativas, lo que hace que este modelo resulte especialmente adecuado.

En segundo lugar, la regresión logística ofrece un elevado nivel de interpretabilidad, ya que sus coeficientes pueden analizarse directamente como estimaciones de la importancia relativa de cada dimensión de valor en el proceso de decisión.

Finalmente, dado que cada agente únicamente dispone de un número reducido de observaciones de preferencia, el uso de modelos más complejos habría incrementado el riesgo de sobreajuste sin aportar ventajas claras en términos de interpretabilidad o rendimiento.

La variable objetivo se define como:

$$y = \begin{cases} 1 & \text{si el agente elige A} \\ 0 & \text{si el agente elige B} \end{cases}$$

Las variables de entrada corresponden a las diferencias entre valores:

$$X = [\Delta v_1, \Delta v_2, \Delta v_3]$$

El modelo estima coeficientes que reflejan cuánto influye cada valor en la decisión del agente:

$$P(A) = \sigma(w_1 \Delta v_1 + w_2 \Delta v_2 + w_3 \Delta v_3)$$

donde σ representa la función logística.

Posteriormente, los pesos negativos se truncaron a cero y se normalizaron para facilitar su interpretación:

$$\sum_{i=1}^3 w_i = 1$$

El resultado de esta fase es un vector de pesos por agente:

$$(w_1, w_2, w_3)$$

que representa su sistema de valores individual.

Dado que cada agente únicamente dispone de nueve observaciones de preferencia, se realizó una validación adicional mediante *Leave-One-Out Cross Validation* para evaluar la capacidad predictiva del modelo y reducir el riesgo de sobreajuste.

En cada iteración, el modelo se entrenó utilizando ocho comparaciones y se evaluó sobre la observación restante, repitiendo el proceso para cada preferencia disponible por agente.

Los resultados obtenidos muestran:

- accuracy medio: 66.6 %
- accuracy mediano: 70.8 %

- baseline medio: 64.0 %

El baseline utilizado consiste en predecir siempre la alternativa más frecuentemente elegida por cada agente.

Estos resultados muestran una mejora moderada respecto al baseline y sugieren que, aunque el comportamiento de los agentes presenta una elevada variabilidad, el modelo logra capturar parcialmente patrones consistentes de decisión.

Dado que el objetivo principal del trabajo es interpretar sistemas de valores y no maximizar capacidad predictiva, se priorizó deliberadamente la simplicidad e interpretabilidad del modelo frente a arquitecturas más complejas.

9.3. Agrupación de agentes y sistemas de valores sociales

Una vez obtenidos los pesos individuales, se aplicaron técnicas de clustering para identificar grupos de agentes con prioridades similares.

Se compararon tres algoritmos distintos:

- K-Means
- Clustering jerárquico
- Gaussian Mixture Models

La selección de estos algoritmos responde al objetivo de comparar enfoques conceptualmente distintos de agrupación no supervisada.

K-Means representa un enfoque particional basado en centroides y constituye uno de los métodos más utilizados por su simplicidad e interpretabilidad.

El clustering jerárquico permite analizar estructuras de agrupación sin asumir explícitamente centroides, siendo útil para detectar posibles relaciones jerárquicas entre agentes.

Por su parte, Gaussian Mixture Models introducen un enfoque probabilístico más flexible, permitiendo modelar clusters con fronteras menos rígidas.

La comparación entre estos tres métodos permite evaluar si la estructura social identificada depende del algoritmo utilizado o si emerge de forma robusta bajo distintos supuestos de agrupación.

Antes del clustering, los pesos fueron estandarizados para evitar sesgos derivados de escalas distintas.

El número de clusters se fijó en:

$$k = 3$$

con el objetivo de identificar grupos sociales fácilmente interpretables.

Para evaluar la calidad de los agrupamientos se utilizaron:

- silhouette score
- adjusted rand index

Esta fase permite pasar de sistemas de valores individuales a estructuras sociales agregadas.

9.4. Incorporación de normas

La última fase del modelo introduce una capa normativa externa.

El objetivo consiste en analizar cómo determinadas restricciones afectan a agentes con sistemas de valores distintos.

Se implementó una norma sencilla que penaliza alternativas con bajo rendimiento en el segundo valor:

$$penalty(v_2) = \begin{cases} \lambda & \text{si } v_2 < \theta \\ 0 & \text{en otro caso} \end{cases}$$

donde:

- λ representa la intensidad de la penalización
- θ representa el umbral normativo

En la implementación experimental se utilizaron los siguientes parámetros:

$$\lambda = 0,5$$

$$\theta = -0,2$$

El valor de λ determina la magnitud de la penalización aplicada cuando una alternativa presenta un rendimiento insuficiente en v_2 , mientras que θ define el nivel

mínimo aceptable para dicha dimensión.

Estos parámetros fueron seleccionados de forma deliberadamente sencilla con el objetivo de introducir una intervención normativa visible sin alterar de forma extrema el comportamiento agregado del sistema.

Durante fases preliminares del experimento se realizaron pruebas exploratorias con distintos niveles de penalización.

Valores de λ significativamente inferiores generaban cambios prácticamente irrelevantes en el comportamiento agregado, mientras que penalizaciones demasiado elevadas provocaban modificaciones excesivas y reducían artificialmente la autonomía decisional de los agentes.

El valor $\lambda = 0,5$ fue finalmente seleccionado por representar un equilibrio razonable entre visibilidad experimental y preservación del comportamiento original del sistema.

De forma análoga, el umbral $\theta = -0,2$ fue definido para identificar únicamente aquellas alternativas con un rendimiento claramente bajo en v_2 .

Umrales más restrictivos reducían excesivamente el número de intervenciones normativas, mientras que valores demasiado permisivos provocaban penalizaciones sobre alternativas que no podían considerarse claramente problemáticas.

De este modo, el valor seleccionado permitió focalizar la intervención normativa sobre casos donde existía una desviación suficientemente significativa respecto a dicha dimensión valorativa.

En términos prácticos, esta norma puede interpretarse como una restricción externa que protege explícitamente una de las dimensiones valorativas frente a decisiones individuales que podrían ignorarla.

El objetivo no es modelar una normativa real específica, sino introducir una intervención suficientemente simple que permita analizar cómo restricciones colectivas afectan a agentes con preferencias heterogéneas.

La utilidad individual se calcula como:

$$U(x) = \sum_{i=1}^3 w_i v_i$$

Tras aplicar la norma:

$$U'(x) = U(x) - \textit{penalty}(x)$$

Posteriormente se comparan:

- decisión original
- decisión bajo regulación normativa

Esto permite medir el grado en que las normas alteran el comportamiento individual y colectivo.

Los resultados finales se almacenan en archivos CSV y se complementan con visualizaciones automáticas generadas mediante `matplotlib`.

10. Diseño experimental

Una vez implementado el modelo completo, se diseñó una serie de experimentos con el objetivo de evaluar empíricamente las hipótesis planteadas en la Sección 8.

El diseño experimental busca analizar tres dimensiones principales del problema:

- la capacidad de aprender sistemas de valores individuales,
- la existencia de estructuras sociales diferenciadas,
- el impacto de restricciones normativas sobre distintos grupos.

Para ello, se definieron varios experimentos secuenciales que utilizan como entrada los resultados generados en etapas anteriores del pipeline.

10.1. Configuración experimental

Todos los experimentos fueron ejecutados utilizando el dataset procesado derivado de Apollo, compuesto por:

- 3492 comparaciones entre alternativas
- 388 agentes distintos
- 3 dimensiones de valor

Tras la fase de aprendizaje individual, se obtuvieron sistemas de valores para 386 agentes.

Dos agentes fueron descartados debido a que sus preferencias no presentaban suficiente variabilidad para entrenar modelos de regresión logística.

El entorno experimental fue implementado completamente en Python utilizando:

- `pandas`
- `numpy`
- `scikit-learn`
- `matplotlib`

Todos los experimentos fueron ejecutados sobre los mismos datos para garantizar comparabilidad entre resultados.

10.2. Comparación entre algoritmos de clustering

Para evaluar la existencia de grupos sociales diferenciados se compararon tres algoritmos de clustering:

1. K-Means
2. Clustering jerárquico aglomerativo
3. Gaussian Mixture Models

El objetivo principal de este experimento consiste en determinar si la estructura social detectada depende del algoritmo utilizado o si emerge de forma consistente.

El número de clusters se fijó en $k = 3$ por dos motivos principales.

En primer lugar, esta decisión está alineada con el planteamiento de Holgado-Sánchez et al. [3], quienes argumentan que una sociedad no debe modelarse mediante un único sistema de valores homogéneo, sino mediante múltiples grupos con prioridades diferenciadas.

En segundo lugar, un análisis exploratorio preliminar sobre los pesos aprendidos mostró la aparición de tres perfiles dominantes claramente interpretables: agentes orientados principalmente hacia el valor 1, agentes orientados hacia el valor 2 y agentes orientados hacia el valor 3.

Utilizar valores superiores de k generaba una fragmentación adicional sin aportar mejoras sustanciales en interpretabilidad ni separación entre grupos.

Los pesos fueron normalizados antes de aplicar clustering para evitar sesgos derivados de escalas diferentes.

10.3. Evaluación del impacto normativo

El tercer experimento analiza cómo una norma externa modifica las decisiones individuales.

Para ello, se compararon dos escenarios:

- decisiones sin regulación normativa
- decisiones bajo restricciones normativas

La norma penaliza alternativas con bajo rendimiento en el segundo valor.

El objetivo consiste en medir:

- cuántas decisiones cambian
- qué dirección siguen dichos cambios
- qué grupos sociales resultan más afectados

Este experimento permite estudiar conflictos entre preferencias individuales y regulación colectiva.

10.4. Métricas utilizadas

Para evaluar los resultados se utilizaron distintas métricas según cada experimento.

10.4.1. Aprendizaje de valores

- distribución de pesos aprendidos
- medias por valor
- dispersión entre agentes

10.4.2. Clustering

- silhouette score
- adjusted rand index
- tamaño de clusters
- centroides de cada grupo

El silhouette score permite medir separación entre clusters:

$$s(i) = \frac{b(i) - a(i)}{\max(a(i), b(i))}$$

donde:

- $a(i)$ representa cohesión interna
- $b(i)$ representa separación externa

10.4.3. Impacto normativo

- porcentaje global de decisiones modificadas
- transiciones entre decisiones
- porcentaje de impacto por cluster

Estas métricas permiten evaluar no únicamente si las normas cambian decisiones, sino también cómo afectan de manera desigual a distintos grupos sociales.

Adicionalmente, en la fase de aprendizaje de valores se utilizó accuracy predictiva mediante validación *Leave-One-Out* como métrica complementaria para evaluar la capacidad del modelo de regresión logística para reproducir preferencias observadas.

Parte V

Resultados y discusión

11. Resultados

Esta sección presenta los principales resultados obtenidos tras ejecutar el pipeline experimental descrito en las secciones anteriores.

Los resultados permiten evaluar empíricamente las hipótesis planteadas sobre aprendizaje de valores, formación de grupos sociales y efectos de regulación normativa.

11.1. Sistemas de valores aprendidos

El primer resultado relevante consiste en verificar si es posible inferir sistemas de valores individuales a partir de preferencias observadas.

Tras ejecutar el modelo de regresión logística sobre las preferencias de los agentes, se obtuvieron pesos individuales para 386 agentes.

Las estadísticas agregadas fueron las siguientes:

- media de w_1 : 0.261
- media de w_2 : 0.150
- media de w_3 : 0.588

Los resultados muestran que, en promedio, el tercer valor domina claramente las decisiones individuales.

La Figura 1 muestra la distribución completa de los pesos aprendidos para cada dimensión valorativa.




Figura 1: Distribución de pesos de valores aprendidos

Los resultados revelan una distribución altamente heterogénea de prioridades valorativas entre agentes.

El valor v_3 presenta la mediana más elevada, lo que indica que constituye la dimensión dominante para una gran parte de la población.

Por el contrario, v_2 muestra una mediana cercana a cero y una distribución fuertemente concentrada en valores bajos, lo que sugiere que únicamente una minoría de agentes lo prioriza de forma significativa.

El valor v_1 presenta una situación intermedia: aunque muchos agentes le asignan

pesos reducidos, existe un subconjunto claramente diferenciado que le otorga una importancia muy elevada.

Estos resultados sugieren que la población no sigue un sistema de valores homogéneo, sino que presenta una estructura heterogénea de preferencias, lo cual resulta consistente con la hipótesis de diversidad valorativa planteada en este trabajo y justifica posteriormente el uso de técnicas de clustering.

11.2. Resultados del clustering

Una vez aprendidos los sistemas de valores individuales, se procedió a identificar grupos sociales con prioridades similares.

El algoritmo K-Means detectó tres clusters claramente diferenciados:

- Cluster 0: agentes orientados al valor 2
- Cluster 1: agentes orientados al valor 1
- Cluster 2: agentes orientados al valor 3

La Figura 2 representa visualmente la distribución de agentes.




Figura 2: Distribución de agentes según pesos aprendidos

Se observa una separación relativamente clara entre grupos, especialmente entre agentes altamente especializados en un único valor.

La Figura 3 muestra los centroides medios de cada grupo.




Figura 3: Centroides de clusters obtenidos mediante K-Means

Los centroides muestran una fuerte especialización ética en cada grupo social.

11.3. Comparación entre K-Means, clustering jerárquico y GMM

Para analizar la robustez de los resultados, se compararon tres algoritmos distintos de clustering.

La Figura 4 resume los resultados obtenidos mediante silhouette score.




Figura 4: Comparación entre algoritmos de clustering

Los resultados muestran que:

- K-Means obtuvo el mejor rendimiento
- el clustering jerárquico produjo resultados muy similares
- Gaussian Mixture Model obtuvo resultados significativamente inferiores

Además, el elevado adjusted rand index entre K-Means y clustering jerárquico refuerza la estabilidad de la estructura social detectada.

Esto sugiere que los grupos encontrados no son un artefacto específico de un algoritmo concreto.

11.4. Impacto global de las normas

El siguiente experimento analizó el efecto agregado de la norma introducida sobre las decisiones individuales.

La norma modificó:

169

decisiones de un total de:

3474

lo que representa aproximadamente:

4,86 %

del total.

La Figura 5 resume este resultado.




Figura 5: Impacto global de la norma

Aunque el porcentaje total parece relativamente reducido, demuestra que incluso normas simples pueden alterar comportamientos individuales.

La Figura 6 muestra cómo se distribuyen estos cambios.




Figura 6: Transiciones de decisión tras aplicar normas

La Figura 6 permite analizar con mayor detalle la dirección de los cambios producidos por la norma.

Las transiciones $A \rightarrow A$ y $B \rightarrow B$ representan decisiones que permanecen estables tras la regulación normativa.

Por el contrario, las transiciones $A \rightarrow B$ y $B \rightarrow A$ representan decisiones modificadas por la intervención normativa.

Los resultados muestran que la gran mayoría de decisiones permanecen estables, mientras que únicamente una fracción reducida cambia de alternativa. Además, las transiciones $A \rightarrow B$ y $B \rightarrow A$ presentan magnitudes similares, lo que sugiere que la norma no favorece sistemáticamente una alternativa concreta, sino que actúa corrigiendo situaciones específicas en las que determinadas opciones incumplen el criterio regulatorio asociado a v_2 .

11.5. Impacto de las normas por grupo social

Finalmente, se analizó si todos los grupos sociales eran afectados por igual.

La Figura 7 muestra el porcentaje de decisiones modificadas por cluster.




Figura 7: Impacto normativo por cluster

Los resultados muestran diferencias significativas:

- Cluster 0: 2.04 %
- Cluster 1: 9.62 %
- Cluster 2: 3.34 %

El cluster centrado en el valor 1 resulta claramente más afectado por la regulación normativa.

Este resultado presenta una implicación especialmente interesante.

A priori, podría esperarse que el cluster más afectado por la norma fuese el Cluster 0, ya que este grupo es el que otorga mayor peso al valor v_2 , precisamente la dimensión sobre la que actúa la restricción normativa.

Sin embargo, los resultados muestran lo contrario: el grupo más afectado es el Cluster 1, con un 9.62 % de decisiones modificadas, frente al 2.04 % del Cluster 0 y el 3.34 % del Cluster 2.

Una posible explicación es que los agentes del Cluster 1, al priorizar principalmente el valor v_1 , tienden a aceptar con mayor frecuencia alternativas con bajo rendimiento en v_2 cuando ello favorece su objetivo principal.

En consecuencia, la norma interviene con mayor frecuencia sobre este grupo, corrigiendo decisiones que anteriormente ignoraban parcialmente el valor regulado.

Por el contrario, los agentes del Cluster 0 ya incorporan de forma natural el valor v_2 en sus decisiones, por lo que su comportamiento previo se encontraba más alineado con la restricción normativa y requiere menos correcciones externas.

El Cluster 2 presenta un comportamiento intermedio, lo que sugiere una menor exposición al conflicto entre el valor regulado y su sistema de preferencias dominante.

Este resultado refuerza la idea de que los efectos distributivos de una norma no dependen únicamente del valor que pretende proteger, sino también de cómo distintos grupos estructuran sus procesos de decisión.

12. Discusión

Los resultados obtenidos permiten extraer varias implicaciones relevantes para el estudio de la alineación de valores en sistemas multiagente.

En particular, el trabajo aporta evidencia empírica sobre tres cuestiones fundamentales:

- la posibilidad de inferir valores a partir de preferencias observadas,
- la existencia de heterogeneidad ética dentro de una población,
- el impacto desigual de las normas sobre distintos grupos sociales.

Aunque el entorno experimental utilizado es simplificado, los resultados obtenidos resultan consistentes con varios de los problemas teóricos discutidos en la literatura.

12.1. Relación con la literatura previa

Los resultados del aprendizaje de valores son coherentes con el trabajo de Holgado-Sánchez et al. [3], quienes plantean que las preferencias observadas pueden utilizarse para reconstruir sistemas de valores latentes.

El presente trabajo reproduce parcialmente dicha lógica, aunque utilizando una implementación más ligera y completamente desacoplada del entorno original Apollo.

Mientras que Holgado se centra principalmente en inferir preferencias sociales agregadas, este trabajo introduce una capa adicional de análisis mediante clustering social y evaluación normativa.

En este sentido, el trabajo amplía parcialmente el alcance experimental del artículo original.

Por otra parte, los resultados también son consistentes con el marco conceptual de Value-Aware Multi-Agent Systems propuesto por Osman [2], que defiende la necesidad de diseñar agentes capaces de razonar explícitamente sobre valores.

La existencia de clusters claramente diferenciados refuerza la idea de que los sistemas multiagente deben asumir diversidad ética interna en lugar de presuponer homogeneidad moral.

Asimismo, los resultados normativos conectan directamente con el trabajo de Montes y Sierra [4], quienes estudian la generación de sistemas normativos alineados con valores.

Mientras que su enfoque se centra en sintetizar normas óptimas, este trabajo analiza empíricamente cómo dichas normas pueden afectar de forma desigual a distintos grupos.

Finalmente, las limitaciones observadas en la representación simplificada de normas conectan con los problemas señalados por Dennis y Fisher [5] sobre la dificultad de formalizar razonamiento ético complejo.

12.2. Limitaciones del enfoque

A pesar de los resultados obtenidos, este trabajo presenta varias limitaciones importantes.

En primer lugar, el entorno experimental utilizado simplifica considerablemente la complejidad de los sistemas multiagente reales.

Los agentes únicamente realizan elecciones binarias entre alternativas estáticas, sin interacción estratégica compleja ni dinámicas temporales.

En segundo lugar, el modelo de aprendizaje utilizado asume una función lineal de utilidad basada en regresión logística.

En escenarios reales, las preferencias humanas pueden presentar:

- no linealidades
- inconsistencias
- cambios contextuales

En tercer lugar, la norma implementada es deliberadamente sencilla.

Aunque esto facilita el análisis experimental, no captura la complejidad de sistemas normativos reales donde pueden existir:

- múltiples normas simultáneas
- conflictos normativos
- mecanismos de sanción
- adaptación dinámica

Finalmente, el dataset utilizado procede de un entorno simulado.

Por tanto, no puede asumirse automáticamente que los resultados generalicen a preferencias humanas reales.

12.3. Implicaciones para sistemas multiagente éticos

A pesar de sus limitaciones, este trabajo sugiere varias implicaciones relevantes para futuros sistemas multiagente éticos.

En primer lugar, muestra que la alineación de valores no debe entenderse como un problema puramente individual.

En contextos sociales, diferentes grupos pueden priorizar valores distintos, lo que introduce problemas de agregación y conflicto colectivo.

En segundo lugar, los resultados muestran que las normas pueden generar efectos distributivos asimétricos.

Una misma norma puede beneficiar a ciertos grupos mientras perjudica desproporcionadamente a otros.

Este problema resulta especialmente relevante en contextos como:

- plataformas digitales
- sistemas autónomos
- gobernanza algorítmica

Finalmente, los resultados sugieren que futuros sistemas multiagente deberían integrar simultáneamente:

- aprendizaje de preferencias
- modelado de diversidad ética
- mecanismos normativos adaptativos

La combinación de estos elementos representa una línea prometedora para avanzar hacia sistemas multiagente verdaderamente alineados con valores humanos complejos y socialmente diversos.

Parte VI

Conclusiones

13. Conclusiones y líneas futuras

Este trabajo ha abordado el problema de la alineación de valores en sistemas multiagente desde una perspectiva integradora que combina teoría ética, aprendizaje automático y regulación normativa.

A lo largo del documento se ha analizado cómo distintos trabajos previos han abordado de forma parcial problemas relacionados con:

- representación de valores
- aprendizaje de preferencias
- diversidad moral
- diseño normativo

Sin embargo, una de las principales conclusiones del estado del arte es que estos componentes suelen estudiarse de forma aislada.

En respuesta a esta limitación, este trabajo propuso un pipeline experimental que integra estos elementos dentro de un mismo marco.

Desde una perspectiva más amplia, los resultados obtenidos sugieren que la alineación de valores en sistemas multiagente no debe entenderse únicamente como un problema de aprendizaje individual.

Cuando múltiples agentes con prioridades heterogéneas interactúan dentro de un mismo entorno, emergen problemas adicionales de coordinación, conflicto y gobernanza colectiva.

En este contexto, aprender valores individuales constituye únicamente una parte del problema: resulta igualmente necesario comprender cómo se agregan socialmente

dichos valores y cómo las normas pueden intervenir para equilibrar tensiones entre autonomía individual y objetivos colectivos.

El sistema desarrollado permite:

1. inferir sistemas de valores individuales a partir de preferencias observadas,
2. agrupar agentes según prioridades éticas similares,
3. introducir restricciones normativas,
4. analizar el impacto diferencial de dichas normas.

Los resultados experimentales obtenidos muestran que efectivamente es posible reconstruir sistemas de valores individuales utilizando preferencias observadas.

Asimismo, los experimentos de clustering revelaron la existencia de grupos sociales claramente diferenciados, lo que refuerza la idea de que los sistemas multiagente deben ser diseñados considerando heterogeneidad ética interna.

Por otra parte, la incorporación de normas mostró que incluso mecanismos regulatorios relativamente simples pueden alterar decisiones individuales y afectar de manera desigual a distintos grupos.

Este resultado constituye una de las principales aportaciones del trabajo, ya que introduce una dimensión distributiva que frecuentemente recibe menos atención en la literatura sobre alineación.

En términos metodológicos, el trabajo también aporta una implementación completamente reproducible e independiente del entorno original Apollo, facilitando futuras extensiones experimentales.

13.1. Conclusiones principales

Las principales conclusiones del trabajo pueden resumirse en cuatro ideas:

1. Las preferencias observadas contienen suficiente información para inferir prioridades valorativas latentes.
2. Las sociedades artificiales pueden presentar diversidad ética estructurada en grupos diferenciados.
3. Los resultados de clustering muestran robustez entre distintos algoritmos.
4. Las normas pueden generar efectos asimétricos entre distintos grupos sociales.

En conjunto, estos resultados refuerzan la necesidad de abordar la alineación de valores como un problema simultáneamente individual, social y normativo.

13.2. Líneas futuras de investigación

Este trabajo abre múltiples líneas de investigación futuras.

En primer lugar, sería interesante utilizar modelos de aprendizaje más complejos que permitan capturar preferencias no lineales o dinámicas.

Por ejemplo:

- redes neuronales
- inverse reinforcement learning
- modelos bayesianos

En segundo lugar, podrían incorporarse dinámicas multiagente más realistas donde los agentes interactúen estratégicamente entre sí.

Esto permitiría estudiar fenómenos como:

- negociación
- cooperación
- conflicto

En tercer lugar, sería especialmente interesante extender el componente normativo hacia sistemas más sofisticados capaces de:

- generar normas automáticamente
- adaptar normas dinámicamente
- resolver conflictos normativos

Finalmente, una línea especialmente prometedora consistiría en validar este tipo de modelos utilizando datos reales de preferencias humanas en lugar de entornos simulados.

Esto permitiría acercar este tipo de sistemas a aplicaciones reales en gobernanza algorítmica, plataformas digitales y sistemas autónomos.

Parte VII

Bibliografía y material complementario

14. Bibliografía

- [1] Virginia Dignum. «Responsible autonomy». En: *arXiv preprint arXiv:1706.02513* (2017).
- [2] Nardine Osman. «Value-Aware Multiagent Systems». En: *International Workshop on Coordination, Organizations, Institutions, Norms, and Ethics for Governance of Multi-Agent Systems*. Springer. 2024, págs. 32-37.
- [3] Andrés Holgado-Sánchez et al. «Learning the value systems of societies from preferences». En: *arXiv preprint arXiv:2507.20728* (2025).
- [4] Nieves Montes y Carles Sierra. «Synthesis and properties of optimally value-aligned normative systems». En: *Journal of Artificial Intelligence Research* 74 (2022), págs. 1739-1774.
- [5] Louise A Dennis y Michael Fisher. «Specifying Agent Ethics». En: *International Workshop on Coordination, Organizations, Institutions, Norms, and Ethics for Governance of Multi-Agent Systems*. Springer. 2024, págs. 3-14.

15. Material complementario

Con el objetivo de garantizar la reproducibilidad del trabajo, se pone a disposición el repositorio completo con todo el código desarrollado durante la fase experimental.

El repositorio incluye:

- dataset procesado utilizado en los experimentos (`apollo_preferences_dataset.csv`)
- script de aprendizaje de pesos individuales (`learn_value_weights.py`)
- script de validación del modelo de aprendizaje (`evaluate_learning.py`)
- script de agrupación de agentes (`cluster_agents.py`)
- script de aplicación de normas (`apply_norms.py`)
- script de análisis del impacto normativo por cluster (`analyze_norms_by_cluster.py`)

- script de generación automática de visualizaciones (`create_plots.py`)
- resultados experimentales y gráficos generados automáticamente

El repositorio puede consultarse en:

<https://github.com/jcapilla780/Value-Alignment-MAS>

Asimismo, el repositorio incluye un archivo `README.md` con instrucciones detalladas para ejecutar secuencialmente todo el pipeline experimental.

Los experimentos fueron desarrollados en Python utilizando principalmente las librerías:

- `pandas`
- `numpy`
- `scikit-learn`
- `matplotlib`